

Análise do Uso de Informações de Profundidade para Classificação de Objetos em Linhas de Transmissão com um Sensor Multimodal

Resumo—Este trabalho apresenta o desenvolvimento e avaliação de modelos de aprendizado de máquina aplicados à classificação de objetos em linhas de transmissão, utilizando dados de profundidade capturados por uma câmera RealSense D415, um sensor LiDAR RPLIDAR A1 da Slamtec e a combinação de ambos. Foram testados cinco modelos — *k-Nearest Neighbors*, *Árvore de Decisões*, *Naive Bayes*, *Rede Neural* e *Floresta Aleatória* — com dados simulados e reais. Os resultados indicaram que o uso de apenas um dos sensores já permite uma classificação satisfatória, mas a fusão sensorial torna o sistema mais robusto. Os modelos mais leves apresentaram desempenho competitivo, evidenciando seu potencial para futura implementação embarcada. O estudo também explora técnicas de pré-processamento de imagens e dados para a criação de *features* utilizadas no treinamento dos modelos. Destaca-se, assim, a viabilidade do uso de sensores de profundidade na inspeção autônoma de linhas de transmissão, com ganhos em segurança e redução de custos operacionais.

Palavras-Chave—aprendizado de máquina, sensores de profundidade, inspeção autônoma, fusão sensorial, classificação de objetos.

I. INTRODUÇÃO

A inspeção de linhas de alta tensão é crucial para garantir a segurança e eficiência no fornecimento de energia a diversos setores. Essas estruturas operam em ambientes adversos e estão sujeitas a danos causados por condições climáticas extremas. Tradicionalmente, a inspeção é feita por equipes que escalam torres ou utilizam drones. Embora drones cubram grandes áreas com agilidade e baixo custo, enfrentam limitações como autonomia reduzida, dependência de visibilidade e menor precisão em detalhes complexos. Já a inspeção manual, embora precisa, apresenta altos custos, riscos operacionais e baixa escalabilidade.

Com o avanço das tecnologias de inspeção, os métodos tradicionais aplicados em instalações de energia têm se mostrado insuficientes para atender às demandas atuais do setor, principalmente devido à baixa eficiência das inspeções manuais, aos altos riscos envolvidos e à detecção limitada de falhas potenciais. Nesse cenário, observa-se um crescente interesse na automação dessas tarefas por meio de sistemas robóticos embarcados, capazes de percorrer fisicamente os cabos das linhas de transmissão e realizar inspeções de forma autônoma e contínua [7]. Tais sistemas podem ser equipados com sensores capazes de capturar informações detalhadas dos componentes da linha, mesmo em condições adversas. Entre os sensores, destacam-se as câmeras de profundidade, como a RealSense D415, e os sensores LiDAR, como o RPLIDAR A1, que

permitem a obtenção de dados tridimensionais da cena com alta precisão.

Este trabalho investiga o uso de modelos de aprendizado de máquina para a classificação de objetos em linhas de transmissão, com dados de sensores em ambientes simulados e reais. A análise considera dados da RealSense, do LiDAR e a combinação dos dois, com foco na eficiência, no processamento embarcado e em técnicas de pré-processamento e extração de *features*.

Diversas topologias de robôs que se deslocam presos aos cabos das linhas de transmissão têm sido propostas na literatura, visando adaptar-se às diferentes demandas de inspeção e operação nesses ambientes. Um exemplo recente é o *Raccoon-Bot* [3], um robô autônomo projetado para rastreamento solar e monitoramento ambiental contínuo. O sistema é alimentado por painéis solares e carrega sensores para coleta de dados ao longo de linhas suspensas, sendo baseado em topologias robóticas que se apoiam em dois cabos para garantir maior estabilidade e mobilidade. Além disso, têm sido propostos estudos voltados à análise da estabilidade de movimento de robôs do tipo *straddle*, voltados à manutenção de linhas de distribuição. Um desses trabalhos desenvolve e testa, em ambiente laboratorial, três diferentes cenários operacionais que simulam situações comuns enfrentadas por robôs ao longo do cabo, empregando motores com contrapesos e mecanismos de travamento como estratégias para garantir o equilíbrio e a aderência ao condutor durante a operação [2].

Além dos avanços na mobilidade e estabilidade dos robôs de inspeção, também foram desenvolvidas pesquisas voltadas à classificação de objetos presentes em linhas de transmissão. Um exemplo é o trabalho [7] que propõe um robô de inspeção com sistema visual montado em uma plataforma com movimento em dois eixos, onde foram utilizadas imagens para realizar a classificação de componentes utilizando a arquitetura *YOLOv3*. O estudo analisou o impacto da iluminação nas taxas de acerto, alcançando uma acurácia de 94,26% sob luz visível e 68,05% sob luz infravermelha, além de avaliar o efeito da velocidade do robô na taxa de erro da classificação. Em outra abordagem, foi explorado o uso de sensores LiDAR para a identificação de objetos ao longo da linha, como no caso de um robô com sensor UTM-30LX posicionado a 45° abaixo do cabo. Os dados coletados foram utilizados para estimar o diâmetro dos objetos observados, e essas estimativas serviram como base para a classificação dos componentes. O estudo também investiga o comportamento do sensor diante

de diferentes texturas e distâncias, destacando as vantagens e limitações do LiDAR nesse tipo de aplicação [4]. Essa abordagem serviu como inspiração para o presente trabalho no que diz respeito ao uso do sensor LiDAR, orientando a estratégia de posicionamento e extração de características baseadas na geometria dos objetos para fins de classificação.

II. METODOLOGIA

Este trabalho baseia-se na análise de dados obtidos por meio de simulações e de experimentos em ambientes montados em laboratório. Para a comunicação entre o robô, os sensores e os códigos responsáveis pela configuração e coleta de dados, foi utilizado o *Robot Operating System* (ROS), uma estrutura de código aberto amplamente adotada na robótica, que oferece um conjunto de bibliotecas e ferramentas para o desenvolvimento de aplicações robóticas modulares e escaláveis [5]. A etapa de simulação foi conduzida no *software CoppeliaSim*, anteriormente conhecido como V-REP. Esse ambiente de simulação é amplamente utilizado na área de robótica devido à sua flexibilidade e capacidade de integrar diferentes sensores, atuadores e controladores. O CoppeliaSim permite a criação de cenários realistas e a realização de testes de forma segura e repetível, sendo uma ferramenta essencial para o desenvolvimento e validação preliminar de algoritmos [6].

A. Objetos a serem classificados

No contexto deste projeto, foram definidas quatro classes principais de objetos a serem reconhecidos pelo sistema: **isoladores poliméricos**, **sinalizadores**, **amortecedores** e **ausência de obstáculos**. A classificação precisa desses elementos é essencial para que o robô possa adaptar seu comportamento e garantir a segurança e a eficiência da inspeção. A Figura 1 ilustra os objetos utilizados como base para o treinamento dos modelos.

- **Isoladores Poliméricos:** Dispositivos responsáveis por isolar eletricamente os condutores das estruturas de suporte. São fundamentais para a segurança e operação estável das linhas de transmissão.
- **Sinalizadores de Linhas de Alta Tensão:** Elementos visuais fixados às linhas com o objetivo de aumentar sua visibilidade, especialmente em áreas próximas a rotas aéreas ou zonas urbanas.
- **Amortecedores:** Componentes que reduzem vibrações e esforços mecânicos nos cabos, contribuindo para a durabilidade e o bom funcionamento da estrutura.
- **Ausência de Obstáculos:** Representa situações em que não há objetos à frente do robô. Essa classe é relevante para garantir o reconhecimento de cenários livres e a tomada de decisão apropriada.

B. Cenas e robô para testes

Para a coleta dos dados utilizados neste trabalho, foi empregado um protótipo de robô desenvolvido para inspeção de linhas de transmissão, capaz de se fixar ao cabo condutor e realizar movimentos para frente e para trás de forma controlada. O robô foi projetado com foco na confiabilidade mecânica e




Figura 1. Objetos utilizados na classificação: (a) amortecedor, (b) isolador e (c) sinalizador.

na capacidade de operar em ambientes reais de inspeção, como apresentado em [1].

As cenas de teste foram elaboradas tanto em ambiente simulado quanto em um cenário físico montado em laboratório. Na simulação, construída no *software CoppeliaSim*, foram posicionadas duas torres com um cabo suspenso entre elas, no qual o robô se encontrava acoplado. Os objetos (isolador, sinalizador e amortecedor) foram dispostos ao longo da linha para simular uma inspeção típica.

Já no ambiente real, foi montada uma estrutura com um cabo de aproximadamente 5 metros de extensão, suspenso entre dois suportes fixos. O robô foi preso ao cabo de maneira semelhante à simulação, e os objetos foram analisados individualmente, sendo posicionados um por vez para facilitar a aquisição de dados organizados por classe. A Figura 2 apresenta uma comparação visual entre as duas configurações utilizadas para os testes.




Figura 2. Cenas utilizadas para aquisição de dados: (a) ambiente simulado no CoppeliaSim; (b) cenário montado em laboratório com o cabo suspenso.

III. CONJUNTO DE DADOS E PRÉ-PROCESSAMENTO

Os dados da RealSense foram armazenados como imagens em escala de cinza, com profundidade de 16 bits por pixel. Cada valor de pixel representa diretamente a distância do objeto à câmera, em milímetros. Por exemplo, um valor decimal de 1000 em um pixel indica que o ponto correspondente está a 1 metro da câmera. A Figura 3 apresenta a imagem em escala de cinza gerada, apresentando a imagem RGB da cena real para referência.




Figura 3. Exemplo de imagens utilizadas: (a) imagem RGB real, (b) imagem de profundidade real com contraste aumentado, e (c) imagem de profundidade simulada.

Para o pré-processamento dessas imagens, foi inicialmente aplicado um *threshold* com valor de 1000, de modo que todos os valores superiores a esse limite fossem zerados. Essa operação representa um corte físico de 1 metro de distância, permitindo que apenas os objetos dentro desse intervalo fossem considerados. Em seguida, foi realizada uma equalização de histograma para melhorar a visualização e o contraste das imagens. A extração de *features* das imagens incluiu o cálculo da média e variância dos valores de profundidade, a aplicação de um filtro Laplaciano para evidenciar bordas, e operações morfológicas sobre a imagem binarizada, com o objetivo de contar os pixels pertencentes ao objeto principal. A Figura 4 mostra o resultado desses métodos.




Figura 4. Exemplos de imagens com pré-processamento: (a) imagem original, (b) imagem com contraste aumentado e threshold e (c) imagem com laplaciano.

Já os dados provenientes do LiDAR foram salvos em arquivos `.csv`, contendo 63 leituras obtidas em uma abertura angular de 20° , correspondente ao campo de visão frontal do sensor. Cada valor representa a distância medida até um obstáculo, em centímetros. A Figura 5 apresenta exemplos dessas leituras para diferentes objetos, ilustrando os perfis característicos registrados para um amortecedor, um isolador e um sinalizador, respectivamente.

O pré-processamento dos dados do LiDAR consistiu na identificação da primeira e da última variação brusca nos valores de distância, o que indica o início e o fim de um objeto detectado. A partir desses pontos, foi calculada a quantidade de amostras entre essas transições e a média dos valores de distância nesse intervalo. Essa abordagem permite uma caracterização compacta e informativa do perfil do objeto observado.

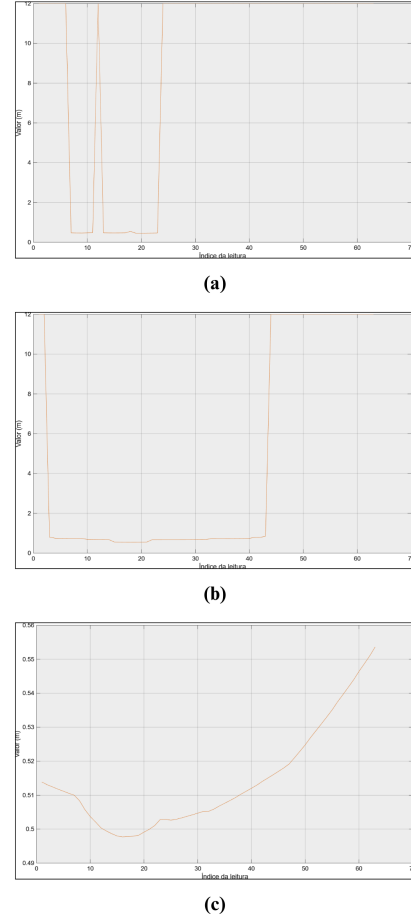


Figura 5. Exemplos de leituras do LiDAR simuladas em cenário controlado: (a) leitura para amortecedor, (b) leitura para isolador, (c) leitura para sinalizador.

IV. RESULTADOS

Nesta seção, são apresentados os resultados obtidos a partir do treinamento e validação dos modelos de classificação com os dados capturados nos cenários simulados e reais. Todos os resultados estão organizados na Tabela I, a qual resume os desempenhos alcançados nos diferentes testes realizados.

Foram conduzidos cinco testes distintos tanto com os dados reais quanto com os dados simulados. No Teste 1, utilizou-se imagens da *RealSense* com equalização de histograma como entrada para uma rede neural convolucional (*SqueezeNet*), que foi retreinada para o problema de classificação. Este teste serviu como *benchmark* para as imagens. No Teste 2, os dados brutos do LiDAR, compostos por 63 amostras de distância distribuídas em 20° de abertura, foram utilizados diretamente como entrada para os modelos de aprendizado de máquina. O Teste 3 utilizou as *features* extraídas das imagens da *RealSense*, conforme descrito anteriormente, enquanto o Teste 4 utilizou as *features* extraídas dos dados do LiDAR. Por fim, o Teste 5 combinou as *features* de ambos os sensores para avaliar o desempenho multimodal.

A Tabela I está organizada da seguinte forma: a primeira coluna indica os dados utilizados (1 para *RealSense*, 2 para *LiDAR*, 3 para ambos); a segunda apresenta o modelo de classificação empregado (kNN, Árvore, Naive, Rede, Floresta, Squeeze); a terceira coluna indica a origem dos dados (real ou simulado); a quarta apresenta a acurácia em porcentagem obtida por validação cruzada com 5 *folds*; e a quinta informa o tempo de validação em milissegundos, medido com base no processamento de 120 amostras. Será apresentado apenas os melhores resultados de cada teste.

Tabela I
RESULTADOS DOS MODELOS DE CLASSIFICAÇÃO

Dados	Modelo	Origem	Acurácia	Tempo de validação
1	Squeeze	Simulação	100.0%	687.0 <i>ms</i>
2	Árvore	Simulação	99.50%	0.1444 <i>ms</i>
1	Árvore	Simulação	100.0%	0.127 <i>ms</i>
2	Árvore	Simulação	98.17%	0.153 <i>ms</i>
3	Árvore	Simulação	100.0%	0.136 <i>ms</i>
1	Squeeze	Real	100.0%	630.6 <i>ms</i>
2	Floresta	Real	100.0%	5.758 <i>ms</i>
1	kNN	Real	100.0%	3.000 <i>ms</i>
2	Floresta	Real	99.14%	5.730 <i>ms</i>
3	kNN	Real	100.0%	2.920 <i>ms</i>

V. DISCUSSÕES E CONCLUSÕES

Analisando os resultados obtidos, observa-se que o uso de apenas um dos sensores já permite realizar a classificação dos objetos com alto grau de acurácia. No entanto, é importante destacar que os dados analisados foram obtidos em ambientes controlados, com interferências externas reduzidas. Em um cenário real de inspeção de linhas de transmissão, diversos fatores físicos podem afetar a precisão dos modelos, como curvaturas acentuadas no cabo, diferentes condições de iluminação e presença de ruídos eletromagnéticos.

Mesmo considerando o ambiente controlado, os testes indicam que a melhor alternativa é utilizar dados provenientes dos dois sensores. A posição física e a estrutura dos objetos influenciam diretamente na performance dos sensores: o sinalizador é bem captado por ambos, o amortecedor é mais bem observado pelo LiDAR, enquanto o isolador é melhor identificado pela câmera de profundidade. Além disso, o próprio cabo condutor só é detectável pelo LiDAR, já que a câmera RealSense não consegue registrá-lo de forma adequada em cenários reais devido às reflexões provocadas pelos materiais do ambiente.

Os modelos treinados apresentaram desempenho satisfatório na maioria dos testes. A rede neural foi o modelo com menor acurácia dentre os avaliados. Como o foco futuro do projeto é a implementação embarcada, optou-se por uma rede de baixa complexidade, o que, aliado ao número reduzido de amostras, frequentemente levou ao *overfitting* durante os *folds* da validação cruzada. Embora tenha sido adotada uma técnica de parada antecipada (*early stopping*), os efeitos do *overfitting* ainda foram perceptíveis. Em um cenário ideal, com mais dados e tempo de treinamento, a rede neural poderia se aproximar da performance da SqueezeNet. No entanto, é evidente o peso

computacional significativamente maior da SqueezeNet, que levou aproximadamente 100 vezes mais tempo para realizar a validação em comparação com os modelos tradicionais mais leves.

Entre os modelos clássicos, o kNN e a Árvore de Decisão apresentaram os melhores desempenhos, tanto em termos de acurácia quanto de tempo de processamento. O modelo Naive Bayes teve o menor tempo de validação entre os métodos tradicionais, porém sua acurácia foi consideravelmente inferior em vários testes. A Floresta Aleatória, por sua vez, mostrou desempenho superior quando aplicada aos dados reais, mas teve tempos de validação mais longos, inclusive superiores aos da própria rede neural em alguns cenários.

Diante desses resultados, a Árvore de Decisão se apresenta como a melhor alternativa para futuras implementações embarcadas do sistema. O modelo obteve acurácia satisfatória em todos os testes, com o pior caso registrando **95 %** ao utilizar as *features* extraídas do LiDAR (Teste 4). Além disso, foi consistentemente o mais rápido para validação, com tempos sempre abaixo de **0,2 milissegundos**. Essa eficiência se deve à simplicidade da estrutura do modelo, que realiza comparações diretas entre *features* para classificar os dados. Em contraste, os modelos kNN e Naive Bayes dependem de cálculos mais custosos, como medidas de distância e estimativas probabilísticas. A estrutura compacta e eficiente da Árvore de Decisão a torna ideal para aplicações embarcadas, atendendo às exigências de desempenho e tempo real exigidas na inspeção autônoma de linhas de transmissão.

REFERÊNCIAS BIBLIOGRÁFICAS

- [1] *****. “*****”. Em: *****. Ed. por *****. *****. *****. *****.
- [2] Shangkun Cheng et al. “Design and Motion Stability Analysis of a Straddle-Type Live Working Robot for Power Distribution Lines”. Em: *Available at SSRN 5139507* (2025).
- [3] Efrain Mendez-Flores, Agaton Pourshahidi e Magnus Egerstedt. “RaccoonBot: An Autonomous Wire-Traversing Solar-Tracking Robot for Persistent Environmental Monitoring”. Em: *arXiv preprint arXiv:2501.14151* (2025).
- [4] Nicolas Pouliot, Pierre-Luc Richard e Serge Montambault. “LineScout power line robot: Characterization of a UTM-30LX LIDAR system for obstacle detection”. Em: *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems*. IEEE. 2012, pp. 4327–4334.
- [5] Morgan Quigley et al. “ROS: an open-source Robot Operating System”. Em: *ICRA workshop on open source software*. Vol. 3. 3.2. Kobe, Japan. 2009, p. 5.
- [6] Eric Rohmer, Surya PN Singh e Marc Freese. “V-REP: A versatile and scalable robot simulation framework”. Em: *2013 IEEE/RSJ international conference on intelligent robots and systems*. IEEE. 2013, pp. 1321–1326.
- [7] Minjie Zhu et al. “Target Recognition of Multi source Machine Vision Pan tilt Integrated Inspection Robot for Power Inspection”. Em: *IEEE Access* (2024).