

## 1 IDENTIFICAÇÃO DO PROJETO

**Projeto Final I - Turma 2024 segundo semestre**

**Título: Análise do Uso de Informações de Profundidade para Classificação de Objetos em Sistemas Elétricos de Potência com um Sensor Multimodal**

Equipe:

Código	Nome	Email	Celular
944980	Alessandro Massayuki Nakatani	nakatani@alunos.utfpr.edu.br	(41) 996230808
2191253	José Mário Nishihara de Albuquerque	josalb@alunos.utfpr.edu.br	(41) 998721623

Professores Orientadores: Prof.º Dr. André Schneider de Oliveira  
Prof.º Dr. Ronnier Frates Rohrich

Resumo:

Este trabalho propõe analisar o desempenho do uso de informações de profundidade de objetos para realizar sua classificação por meio de técnicas de aprendizado de máquina. Para isso, serão utilizados dois sensores: um LiDAR 360° e uma câmera de profundidade, com dados coletados em ambientes simulados no CoppeliaSim e em laboratórios. A finalidade é atender à necessidade de classificação de objetos em linhas de transmissão, oferecendo um método alternativo que dispensa o uso de imagens tradicionais e que possa ser integrado a diferentes topologias de robôs. Os resultados visam beneficiar robôs destinados à inspeção de linhas de transmissão e as empresas responsáveis por sua operação.

Palavras-chave: Classificação de objetos; Linhas de transmissão; Sensor LiDAR; Câmera de profundidade; Aprendizado de máquina; Robôs de inspeção; Automação.

## 2 DESCRIÇÃO DO PROJETO / CARACTERIZAÇÃO

### 2.1 Objetivo Geral

Avaliar o uso de sensores LiDAR 360° e câmeras de profundidade para classificação de objetos de interesse em linhas de transmissão e avaliar os resultados com base no desempenho medido por métricas como acurácia, tempo de processamento e quantidade de informações utilizadas.

### 2.2 Objetivos Específicos

**Desenvolvimento de Códigos de Configuração e Acionamento dos Sensores:** Criar os scripts necessários para configurar e acionar os sensores, utilizando Python para controlar a

captura dos dados. O processo envolverá o desenvolvimento de códigos para coletar imagens de profundidade e dados do LiDAR, com armazenamento em arquivos CSV e imagens.

**Sensor multimodal:** Desenvolver o projeto com a flexibilidade necessária para permitir sua integração em diferentes topologias, incluindo robôs terrestres, aéreos e aqueles que se locomovem diretamente no cabo de linhas de transmissão.

**Montagem de Cenas Simuladas no CoppeliaSim:** Criar cenas simuladas no CoppeliaSim, onde os sensores serão acoplados ao robô, que percorrerá a linha de transmissão. O robô será posicionado entre duas torres, com um cabo rígido esticado entre elas, e os sensores de profundidade e LiDAR 360° serão usados para coletar dados enquanto o robô se move ao longo do cabo. As cenas levarão em consideração o movimento do robô, com acionamento dos motores para simular a coleta de dados em tempo real.

**Montagem de Ambientes Controlados no Laboratório:** Construir ambientes controlados no laboratório, com os sensores presos a mecanismos que simulem diferentes ângulos e distâncias, onde os sensores não estarão no robô. Além disso, será montada uma pequena cena com um cabo pendurado, contendo objetos encontrados em linhas de alta tensão onde o robô será preso ao cabo, com os sensores fixados a ele, e percorrerá o trajeto enquanto coleta dados sobre os objetos presentes no cabo.

**Treinamento de Modelos de Aprendizado de Máquina:** Utilizar os dados coletados para treinar diferentes modelos de aprendizado de máquina, com o objetivo de avaliar a capacidade dos modelos em classificar os objetos presentes nas linhas de transmissão. Para isso, serão montados diferentes datasets, considerando separadamente as informações do LiDAR, da câmera de profundidade e a combinação de ambos, permitindo a análise do impacto de cada sensor na performance dos modelos.

**Avaliação de Desempenho:** Avaliar o desempenho dos modelos treinados, utilizando métricas de performance como acurácia, precisão, recall e tempo de processamento para comparar os resultados obtidos pelos diferentes sensores e modelos.

### 2.3 Diagrama de funcionamento

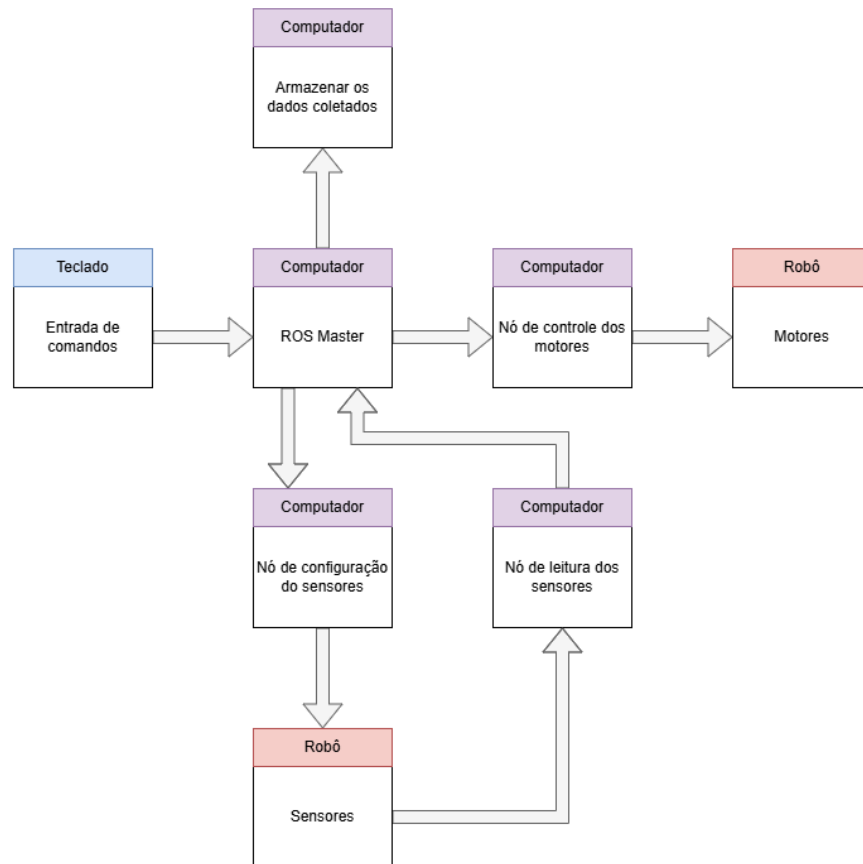


Figura 1 Diagrama de funcionamento. Fonte: Autoria própria.

### 2.4 Descrição de funcionamento

O *Robot Operating System* (ROS) é um sistema operacional para robótica que fornece um conjunto de bibliotecas e ferramentas para o desenvolvimento de aplicações robóticas. Ele permite a comunicação entre diferentes componentes do sistema através de um modelo baseado em nós, onde cada nó representa um processo responsável por uma tarefa específica. O ROS opera utilizando um sistema de *publish-subscribe*, onde nós publicadores enviam mensagens para tópicos específicos, e nós inscritos recebem essas mensagens para processá-las (QUIGLEY et al., 2009).

No contexto do projeto, o ROS será utilizado para gerenciar a comunicação entre os diferentes componentes do robô. Um dos publicadores recebe comandos do teclado e controla os movimentos do robô, permitindo que ele avance, recue e realize a ação de agarrar ou soltar do cabo. Outro publicador é responsável pela configuração e inicialização dos sensores, que

atuam como publicadores, enviando dados que serão recebidos por nós inscritos que salvam essas informações para posterior análise.

#### 2.4.1 Cenas Simuladas

Para a simulação do sistema, será utilizado o *CoppeliaSim*, um simulador de robótica que permite a implementação e teste de sistemas complexos de forma eficiente (ROHMER; SINGH; FREESE, 2013). O robô utilizado na simulação possui comandos básicos de movimento: avançar, recuar e agarrar/soltar do cabo. O ambiente simulado consistirá em duas torres de transmissão conectadas por um cabo cilíndrico, onde o robô estará preso e se deslocará ao longo do cabo. Os objetos de interesse serão posicionados tanto ao longo do cabo quanto dispersos pela cena, simulando elementos reais presentes em uma linha de transmissão.

#### 2.4.2 Cenas Reais

Na implementação real, o sistema contará com uma *Raspberry Pi 5*, que executará o ROS localmente, permitindo a autonomia do robô sem a necessidade de um computador externo. Para o controle dos motores, será utilizado um *Arduino Mega*, devido à quantidade de portas necessárias para a interface com os atuadores.


Os sensores utilizados para a percepção do ambiente incluem um sensor *LiDAR RPLidar A1M8* da *Slamtec*, que realiza leituras a 360° para mapear o entorno do robô, e uma câmera *Intel RealSense D415*, responsável pela captura de imagens de profundidade. Ambos os sensores se comunicam diretamente com a *Raspberry Pi 5* via interface serial, permitindo a coleta e processamento dos dados em tempo real.

#### 2.4.3 Objetos de Interesse

Os principais objetos de interesse na inspeção da linha de alta tensão são os **sinalizadores**, **amortecedores** e **isoladores**. Esses componentes desempenham papéis fundamentais na segurança e estabilidade da infraestrutura elétrica, sendo essenciais para a detecção de anomalias durante a inspeção.

- **Sinalizadores:** São dispositivos instalados ao longo das linhas de transmissão para aumentar sua visibilidade, especialmente em regiões onde há risco de colisão com aeronaves.
- **Amortecedores:** Esses dispositivos reduzem as vibrações mecânicas causadas pelo vento e outras influências ambientais nos cabos da linha de transmissão.
- **Isoladores:** São componentes fundamentais para a separação elétrica entre os cabos de alta tensão e as estruturas metálicas das torres. Eles evitam curtos-circuitos e garantem o isolamento adequado da corrente elétrica.

A **Figura 2** apresenta uma visão geral dos três tipos de objetos mencionados.



*Figura 2 Objetos de interesse. Fonte: Autoria própria.*

### 3 JUSTIFICATIVA E RESULTADOS ESPERADOS

#### 3.1 Justificativa Resumida

A inspeção de linhas de transmissão de alta tensão é um processo essencial para garantir a confiabilidade do fornecimento de energia elétrica, prevenindo falhas que podem gerar grandes prejuízos e até riscos à segurança. Tradicionalmente, essa inspeção era realizada manualmente por técnicos que precisavam escalar as torres ou utilizar drones para capturar imagens das estruturas. No entanto, essas abordagens apresentam diversas limitações, como o risco à integridade física dos trabalhadores e a dificuldade de obtenção de dados precisos em diferentes condições ambientais.

Com o avanço da robótica, diversos modelos de robôs para inspeção de linhas de transmissão foram desenvolvidos, cada um com características específicas para atender às demandas da área. O projeto proposto visa contribuir para essa evolução, participando do desenvolvimento de um robô capaz de percorrer linhas de transmissão e superar os obstáculos encontrados no percurso. Além disso, para viabilizar a navegação autônoma desse robô, foi necessário o uso de sensores para classificar objetos encontrados na linha, tornando a inspeção mais eficiente e confiável.

Os primeiros robôs projetados para a inspeção de linhas de transmissão tinham um funcionamento relativamente simples, sendo totalmente dependentes de operadores humanos. Um exemplo inicial é o robô desenvolvido por Fonseca, Abdo e Alberto (2012), que utilizava um motor a combustão, mas essa abordagem foi descartada devido à impossibilidade de operação segura em redes energizadas. Posteriormente, foi adotado um modelo com motores elétricos, que contava apenas com dois braços e não possuía mecanismos de trava ao cabo ou de superação de obstáculos. Esse robô era controlado via rádio por um operador e equipado com uma câmera RGB para realizar a inspeção visual da linha.

Com a necessidade de superar obstáculos nas linhas de transmissão, novos projetos foram desenvolvidos, incluindo mecanismos mais sofisticados. Um dos primeiros conceitos abordando a superação de obstáculos foi proposto por Tong (2024), no qual um robô equipado

com dois conjuntos de rodas e dois braços mecânicos permitia a travessia de obstáculos verticais curtos. Já o robô apresentado por Yue, Wang e Jiang (2017) foi projetado para escalar jumpers com inclinações de até 80°, utilizando um mecanismo de locomoção similar a uma lagarta, além de uma garra para suporte durante o movimento. No entanto, esse modelo ainda dependia de um operador humano para sua navegação.

Outro robô com capacidade de superar obstáculos foi descrito por Qing et al. (2016). Ele possuía unidades mecânicas para locomoção, abertura e fechamento da estrutura, fixação no cabo e rotação do corpo, mas, assim como os modelos anteriores, sua movimentação exigia um operador para cada etapa do deslocamento, incluindo a travessia de obstáculos. Essa dependência operacional é uma limitação significativa, pois aumenta o tempo e os custos da inspeção, além de exigir um alto nível de habilidade do operador.

Além da inspeção visual, alguns robôs foram desenvolvidos com o objetivo de executar tarefas específicas, como o modelo apresentado por Jiang et al. (2019), que foi projetado com dois braços e uma garra para substituir amortecedores da linha. Embora essa funcionalidade amplie a capacidade do robô, sua operação ainda requer controle humano, limitando sua eficiência.

Sensores de diferentes tipos passaram a ser incorporados aos robôs de inspeção para aumentar sua eficiência e autonomia. Um exemplo é o sistema apresentado por Fan et al. (2018), que integrava sensores RGB, infravermelho e LiDAR. Esse robô foi projetado para coletar dados sobre as linhas de transmissão e superar obstáculos, utilizando sensores de luz visível e infravermelho para analisar a estrutura das mesmas, enquanto o LiDAR era empregado para estimar parâmetros espaciais do ambiente e mapear a vegetação ao redor. Apesar do potencial de funcionamento autônomo, o robô necessita de uma equipe para operá-lo, e a implementação da autonomia não foi abordada no projeto.

Outra abordagem foi apresentada por Qin et al. (2017), que desenvolveram um robô equipado com um sensor LiDAR para coletar dados e reconstruir uma nuvem de pontos 3D da linha de transmissão. Esse sistema permite a modelagem detalhada da estrutura e pode ser útil para aplicações como planejamento de manutenção e detecção de deformações da linha e de objetos presentes nela.

Junto ao desenvolvimento de robôs capazes de percorrer as linhas de transmissão, diversos trabalhos propõem o uso de sensores para realizar a classificação de objetos presentes na linha. Dentre as abordagens mais utilizadas, destacam-se a utilização de sensores LiDAR, tanto para a obtenção de nuvens de pontos quanto para a detecção direta de obstáculos, e o uso de sensores RGB para a análise visual dos componentes da linha.

O artigo de Peters, Ahn e Borkowski (2002) apresenta um robô rastejador de linha projetado para detectar obstáculos e ativar rotinas diferentes para superá-los. Para isso, o robô utiliza 34 sensores distribuídos em sua estrutura, que são simplificados em quatro sensores de proximidade, sendo eles, um sensor para medir a distância do robô ao cabo e três sensores para identificar os obstáculos à frente. A tomada de decisão do robô é baseada nas leituras desses sensores, e, para lidar com as interferências eletromagnéticas das linhas de alta tensão, o trabalho propõe o uso de redes neurais, permitindo que as medições permaneçam precisas mesmo em ambientes ruidosos.

No trabalho POLIBOT – Power Lines Inspection Robot, Lima, Bomfim e Mourão (2018) propõem um robô leve e de baixo custo, projetado para inspecionar as linhas de transmissão com facilidade de instalação e remoção. O robô utiliza um sensor LiDAR em conjunto com um sensor ultrassônico para detectar obstáculos e calcular os ângulos de atuação necessários para a navegação.

Outro estudo relevante é o de Pouliot, Richard e Montambault (2012), que caracteriza o desempenho do sensor LiDAR UTM-30LX em diferentes condições, incluindo variações de temperatura, superfície escaneada, distância e orientação do sensor. O trabalho apresenta uma abordagem onde o sensor, posicionado na parte inferior do robô, realiza varreduras em um ângulo de  $45^\circ$  para detectar objetos na linha, com um campo de visão de  $\pm 12^\circ$ , resultando em 49 medidas por varredura. A abordagem se baseia na identificação das bordas dos objetos para determinar seus diâmetros e a distância média ao sensor. Posteriormente, a sequência do projeto, Introduction of a LIDAR-Based Obstacle Detection System on the LineScout Power Line Robot (Richard, Pouliot e Montambault, 2014), implementa os resultados obtidos e realiza testes em uma linha real. Os resultados indicam que a abordagem permite distinguir objetos na linha com base nas leituras do sensor, porém, o estudo não implementa um modelo específico para a classificação automática dos objetos.

Outro método para classificação utilizando o sensor LiDAR é a geração de nuvens de pontos, que permite uma análise mais detalhada dos objetos presentes na linha. No trabalho de Qin et al. (2018), o sensor LiDAR é utilizado para criar uma nuvem de pontos das linhas de transmissão, onde o processo de classificação dos objetos é realizado com base na distribuição espacial dos pontos, considerando informações físicas das linhas para segmentação e aplicação de técnicas de crescimento de região em 3D. A abordagem alcança uma acurácia média de 90,6%, com uma precisão de 98,2%, demonstrando a viabilidade do método para identificar objetos na linha. O robô utilizado no estudo é o mesmo apresentado no trabalho A Novel Method to Reconstruct Overhead High-Voltage Power Lines Using Cable Inspection Robot LiDAR Data (Qin et al., 2017), que propõe a reconstrução das linhas de alta tensão a partir dos dados obtidos pelo sensor LiDAR.

Por sua vez, Wang et al. (2018) realizam uma comparação sistemática dos métodos de classificação de linhas de transmissão, utilizando nuvens de pontos obtidas por robôs móveis e drones equipados com sensores LiDAR. As informações de profundidade são pré-processadas por métodos de vizinhança local e seleção de atributos para otimizar a identificação dos objetos. O estudo avalia diferentes técnicas de classificação, incluindo SVM, Random Forest, Decision Tree, Naive Bayes, Discriminant Analysis e Redes Neurais, sendo que os melhores resultados são obtidos com Random Forest e Redes Neurais, alcançando até 98,5% de taxa de qualidade.

Além do LiDAR, sensores RGB também são amplamente utilizados para a classificação de objetos na linha. Song et al. (2015) propõem um método baseado em visão computacional para a detecção de espaçadores quebrados em linhas de alta tensão. O processo inicia-se com a extração de uma região de interesse (ROI) contendo o espaçador, seguida da aplicação de transformações morfológicas para segmentar a área de interesse. Com o espaçador isolado, a análise das conexões na imagem permite classificar se o componente apresenta defeitos.

No trabalho de Zhu, Wang e Xu (2016), um robô de inspeção utiliza visão computacional para detectar amortecedores, espaçadores e braçadeiras presentes na linha. O processamento das imagens envolve operações de transformação e técnicas morfológicas para realçar as características dos objetos. A classificação é realizada utilizando uma SVM com restrições estruturais, alcançando uma acurácia de 96% para a braçadeira, 93,33% para o espaçador e 92,67% para o isolador.

A seguir, são listadas as principais vantagens e desvantagens dos sensores utilizados dentro deste contexto:

SENSOR	VANTAGENS	DESVANTAGENS
RGB	<ul style="list-style-type: none"> <li>• Capacidade de diferenciar objetos com base em cores e texturas.</li> <li>• Boa resolução espacial, permitindo análises detalhadas.</li> <li>• Fácil integração com modelos de visão computacional baseados em aprendizado de máquina e redes neurais.</li> </ul>	<ul style="list-style-type: none"> <li>• Sensível a variações de iluminação, podendo comprometer a qualidade da classificação em condições de sombra ou luz intensa.</li> <li>• Dificuldade em diferenciar objetos com cores semelhantes.</li> <li>• Não fornece informações sobre a profundidade ou distância dos objetos, dificultando a estimativa do posicionamento tridimensional dos componentes.</li> </ul>
LiDAR com nuvem de pontos	<ul style="list-style-type: none"> <li>• Alta precisão na determinação da posição e forma dos objetos.</li> <li>• Funciona independentemente das condições de iluminação.</li> <li>• Permite reconstrução tridimensional da cena, possibilitando a análise detalhada da geometria dos objetos.</li> <li>• Facilita a identificação de obstáculos e variações na estrutura da linha de transmissão.</li> </ul>	<ul style="list-style-type: none"> <li>• Processamento de nuvem de pontos pode ser computacionalmente intensivo, exigindo hardware robusto.</li> <li>• Dependendo da densidade da nuvem de pontos, pode ser necessário um pré-processamento complexo para remoção de ruído e segmentação dos objetos.</li> </ul>
LiDAR sem nuvem de pontos	<ul style="list-style-type: none"> <li>• Menor consumo de memória e processamento em comparação com a nuvem de pontos completa.</li> <li>• Boa precisão para detectar a presença e distância de objetos.</li> <li>• Funciona independentemente das condições de iluminação.</li> </ul>	<ul style="list-style-type: none"> <li>• Pode ser insuficiente para identificar e diferenciar objetos com formatos semelhantes.</li> <li>• A detecção fica limitada a poucos pontos de medição, dificultando a identificação de detalhes finos.</li> </ul>
Câmera de Profundidade	<ul style="list-style-type: none"> <li>• Oferece uma forma de visualização 3D sem precisar de processamento pesado como a nuvem de pontos do LiDAR.</li> <li>• Funciona bem em condições de baixa iluminação.</li> </ul>	<ul style="list-style-type: none"> <li>• Qualidade da profundidade pode ser afetada por superfícies refletivas ou muito escuras.</li> <li>• Alcance menor em comparação ao LiDAR, podendo ser insuficiente para capturar objetos distantes na linha de transmissão.</li> <li>• Menor precisão em comparação com a nuvem de pontos LiDAR, dificultando a classificação de pequenos detalhes estruturais.</li> </ul>



## **3.2 Resultados Esperados**

### **3.2.1 Tecnológicos:**

Espera-se desenvolver um método eficiente de classificação de objetos de linhas de transmissão utilizando dados de profundidade. Este trabalho resultará na criação de pipelines de coleta e processamento de dados no ROS, integrando os sensores a um sistema robótico funcional. Além disso, espera-se otimizar o tempo de processamento e a acurácia dos modelos de aprendizado de máquina para aplicações em ambientes reais e simulados. Essa abordagem pode ser estendida a outras áreas que demandem classificação baseada em profundidade.

### **3.2.2 Científicos:**

Este projeto contribuirá com estudos comparando o uso de diferentes tipos de sensores para classificação de objetos baseando-se em informações de profundidade. A análise dos resultados fornecerá insights sobre as limitações e os potenciais desses sensores em cenários específicos. Além disso, o projeto ajudará a expandir o uso de aprendizado de máquina aplicado a dados de profundidade, que ainda é menos explorado em relação ao uso de imagens RGB.

### **3.2.3 Econômicos:**

O sensor multimodal viabiliza a integração em diferentes robôs de inspeção, otimizando a classificação de objetos em linhas de transmissão. A automação desse processo reduz a necessidade de intervenção humana, gerando economia operacional.

### **3.2.4 Sociais:**

O projeto tem o potencial de melhorar a segurança e a eficiência em inspeções de linhas de transmissão, reduzindo o risco de acidentes para trabalhadores em condições adversas. A automação desse processo também pode contribuir para a expansão de redes de energia elétrica em locais de difícil acesso, promovendo o desenvolvimento de comunidades remotas e aumentando a confiabilidade do fornecimento de energia.

## **4 METODOLOGIA E MECANISMOS DE GESTÃO**

### **4.1 Metodologia**

Esta seção abordará as etapas necessárias para o desenvolvimento do projeto, desde a construção dos códigos de configuração e controle dos sensores até o treinamento dos modelos de classificação. Inicialmente, serão desenvolvidos os códigos para a aquisição e processamento dos dados capturados pelos sensores. Em seguida, serão construídos os ambientes utilizados para a aquisição de dados, sendo um ambiente simulado para testes iniciais e um ambiente real no laboratório para validação prática. Após a montagem dos ambientes, será realizada a coleta dos dados, que servirão como base para o treinamento dos

modelos de classificação, permitindo a identificação e categorização dos objetos presentes na linha de transmissão.

#### **4.1.1 Configuração dos Sensores**

Os sensores utilizados no projeto serão configurados por meio dos drivers fornecidos pelo ROS, permitindo a definição de parâmetros como velocidade de operação, resolução e limites mínimo e máximo para as leituras de profundidade. No caso do sensor LiDAR, a versão simulada possibilita a configuração de qualquer número de leituras dentro de qualquer faixa angular, enquanto o sensor real opera sempre com um número fixo de leituras distribuídas em 360°. Para restringir a área de interesse na versão real, será aplicado um corte por software, mantendo o número total de leituras inalterado. Já a câmera de profundidade, tanto na simulação quanto na implementação real, compartilha as mesmas características operacionais, garantindo uniformidade na aquisição de dados.

#### **4.1.2 Análise de topologias**

Desenvolver um módulo adaptável capaz de suportar os sensores e ser integrado a diferentes topologias de robôs, incluindo terrestres, aéreos e aqueles que se deslocam ao longo do cabo de linhas de transmissão. O projeto será concebido com foco na modularidade, permitindo a fácil adaptação dos sensores às diferentes plataformas sem comprometer a eficiência da aquisição e processamento dos dados.

#### **4.1.3 Aquisição de Dados**

A aquisição de dados será realizada por meio de scripts em Python integrados ao ROS, onde os sensores atuarão como publicadores em um nó, enquanto os scripts serão responsáveis pela subscrição e armazenamento das informações recebidas. Os dados do sensor LiDAR serão salvos em arquivos CSV, onde cada coluna representará um ângulo de varredura e os valores armazenados corresponderão às distâncias medidas para cada ângulo específico. Já as informações captadas pela câmera de profundidade serão armazenadas como imagens em escala de cinza, nas quais a intensidade de cada pixel representará a distância relativa do ponto correspondente em relação à câmera.

#### **4.1.4 Construção das Cenas Simuladas**

A simulação será desenvolvida no software CoppeliaSim, utilizando modelos 3D de torres de transmissão, amortecedores, isoladores e sinalizadores. A cena conterá duas torres conectadas por um cabo reto, sem curvatura, para simplificar a simulação. No cabo será acoplado um protótipo de robô capaz de travar e destravar do cabo, além de se deslocar para frente e para trás com velocidade constante. Os sensores serão fixados ao robô, com o LiDAR posicionado abaixo da linha do cabo e a câmera de profundidade acima. A publicação dos dados dos sensores será realizada por meio de scripts em Lua executados diretamente no CoppeliaSim, garantindo a comunicação com o ambiente ROS.

#### 4.1.5 Construção das Cenas no Laboratório

Para a aquisição de dados em ambiente real, serão montados dois cenários distintos. No primeiro, o sensor será posicionado diretamente em frente ao objeto, com uma parede plana ao fundo, permitindo variações nos ângulos e distâncias de captura. O segundo cenário será realizado em um cabo suspenso no laboratório, onde um protótipo de robô será responsável por transportar os sensores. Esse robô terá a capacidade de travar e destravar do cabo, além de se movimentar para frente e para trás com velocidade constante. O cabo suspenso possui aproximadamente 5 metros de comprimento, e os objetos de interesse estarão fixados ao longo dele. O ROS será executado em um Raspberry Pi, que também será responsável pelo armazenamento dos dados coletados.

#### 4.1.6 Treinamento e Avaliação de Modelos

Com os dados coletados das cenas simuladas e do ambiente de laboratório, serão treinados diferentes modelos de classificação. Os modelos serão implementados por meio de scripts em Python, explorando diversas combinações de hiperparâmetros e técnicas de pré-processamento dos dados para otimizar o desempenho. Serão montados diferentes conjuntos de dados, utilizando informações apenas do LiDAR, apenas da câmera de profundidade e a combinação de ambos, permitindo analisar a influência de cada sensor na classificação. A avaliação dos modelos será realizada considerando métricas como acurácia e precisão usando validação cruzada, além de aspectos como uso computacional e simplicidade da arquitetura. A escolha do modelo mais adequado levará em conta a viabilidade de sua implementação embarcada no robô, buscando um equilíbrio entre desempenho e eficiência computacional.

### 4.2 Cronograma Resumido e Datas Importantes

**Junho de 2024 (Semana 1-4):** Definição dos parâmetros dos sensores e configuração dos drivers no ROS.

**Julho de 2024 (Semana 1-2):** Construção das cenas simuladas no CoppeliaSim e integração dos sensores.

**Julho de 2024 (Semana 3-4):** Montagem do ambiente experimental no laboratório e testes iniciais dos sensores.

**Agosto de 2024 (Semana 1-2):** Ajustes e validação da coleta de dados nos ambientes simulado e real.

**Agosto de 2024 (Semana 3-4):** Início da coleta de dados e armazenamento estruturado das informações.

**Setembro de 2024 (Semana 1-4):** Continuação da coleta de dados e início do pré-processamento.

**Outubro de 2024 (Semana 1-4):** Refinamento do pré-processamento e organização dos datasets.

**Novembro de 2024 (Semana 1-4):** Início do treinamento dos modelos de aprendizado de máquina e testes de diferentes combinações de hiperparâmetros.

**Dezembro de 2024 (Semana 1-4):** Avaliação comparativa do desempenho dos modelos treinados.

**Janeiro de 2025 (Semana 1-4):** Implementação de ajustes e otimizações nos modelos escolhidos.

**Fevereiro de 2025 (Semana 1-4):** Testes finais dos modelos e preparação para integração embarcada.

**Março e abril de 2025:** Validação final, ajustes necessários e início da documentação.

**Mai de 2025:** Finalização da documentação e entrega do projeto.

[illegible][illegible]

#### **4.4 Análise de Riscos**

A análise de riscos é uma etapa fundamental para antecipar desafios e garantir o sucesso do projeto. Diversos fatores podem comprometer o desempenho, viabilidade ou segurança do sistema proposto, desde problemas técnicos na implementação do controle até questões financeiras e operacionais. A seguir, são discutidos os principais riscos associados ao desenvolvimento do projeto.

##### **4.4.1 Topologia de controle inadequada**

O sistema de controle do robô precisa garantir a navegação estável ao longo da linha de transmissão, para ter uma coleta eficiente de dados dos sensores. Uma topologia de controle mal projetada pode resultar em instabilidades, falhas na movimentação ou até mesmo a impossibilidade de coletar dados úteis. Além disso, como o processamento das informações ocorre de forma distribuída entre a Raspberry Pi e o Arduino Mega, problemas na comunicação entre esses dispositivos podem comprometer o funcionamento adequado do sistema.

##### **4.4.2 Limitações na Aquisição e Qualidade dos Dados**

Os sensores utilizados possuem características específicas que podem afetar a qualidade dos dados adquiridos. O LiDAR, pode sofrer interferências causadas por reflexões em objetos metálicos ou variações no ambiente, enquanto a câmera de profundidade pode apresentar imprecisões em superfícies muito escuras ou reflexivas.

##### **4.4.3 Riscos Mecânicos e de Segurança**

O robô será projetado para operar em linhas de transmissão de alta tensão, o que exige um sistema mecânico confiável para evitar quedas ou falhas estruturais. Caso o mecanismo de travamento no cabo não funcione corretamente, há risco de perda do equipamento. Além disso, falhas nos atuadores ou nos motores podem impedir a movimentação adequada do robô, comprometendo sua funcionalidade. Outro ponto crítico é a segurança dos operadores durante os testes laboratoriais, pois a manipulação de componentes mecânicos e elétricos pode apresentar riscos de acidentes caso não sejam tomados os devidos cuidados.

##### **4.4.4 Elevado Consumo Computacional e Dificuldade de Embarcamento**

Os algoritmos de visão computacional e aprendizado de máquina utilizados para a classificação de objetos devem ser eficientes o suficiente para rodar em hardware embarcado, como a Raspberry Pi. No entanto, alguns modelos mais robustos podem exigir um poder de processamento elevado, tornando inviável a implementação direta no robô sem otimizações. Esse fator pode exigir estratégias como a redução da complexidade dos modelos ou a necessidade de transmitir os dados para processamento externo, o que comprometeria a autonomia do sistema.

#### **4.4.5 Validação e Generalização dos Modelos**

Os modelos treinados precisam ser capazes de classificar corretamente os objetos em diferentes condições, considerando variações na iluminação, no posicionamento dos sensores e nas características dos componentes inspecionados. Existe o risco de que os modelos apresentem um bom desempenho apenas nos dados coletados no laboratório, mas falhem quando aplicados em cenários reais de inspeção. Isso exigiria novas coletas de dados e ajustes no treinamento, aumentando o tempo de desenvolvimento do projeto.

## **5 DOCUMENTAÇÃO**

### **5.1 Estrutura do Sumário**

1. Introdução
  - 1.1. Justificativa
  - 1.2. Objetivos
  - 1.3. Diagrama de funcionamento
  - 1.4. Estrutura do Documento
2. Revisão Bibliográfica
  - 2.1. Conceitos sobre inspeção em linhas de transmissão
  - 2.2. Sensores para inspeção autônoma
  - 2.3. Algoritmos de aprendizado de máquina aplicados à classificação de objetos
  - 2.4. Tecnologias embarcadas e protocolos de comunicação
3. Metodologia
  - 3.1. Configuração dos Sensores
  - 3.2. Aquisição de Dados
  - 3.3. Construção das Cenas Simuladas
  - 3.4. Construção das Cenas no Laboratório
  - 3.5. Treinamento e Avaliação dos Modelos
4. Desenvolvimento
  - 4.1. Hardware
    - 4.1.1. Estrutura Mecânica
    - 4.1.2. Sensores Utilizados
    - 4.1.3. Sistemas de Controle e Comunicação
  - 4.1. Firmware e Software
    - 4.1.1. Controle do Robô via ROS
    - 4.1.2. Processamento de Dados
    - 4.1.3. Implementação dos Modelos de Classificação

## 5. Testes e Resultados

- 5.1. Testes em Simulação
- 5.2. Testes no Ambiente Real
- 5.3. Avaliação dos Modelos Treinados
- 5.4. Comparação entre Simulação e Realidade

## 6. Discussões e Conclusões

- 5.1. Análise dos Resultados Obtidos
- 5.2. Limitações do Projeto
- 5.3. Conclusões Finais

## 7. Perspectivas para Trabalhos Futuros

- Melhorias no hardware do robô
- Otimização dos algoritmos de classificação
- Testes em ambiente operacional real
- Expansão do sistema para inspeção completa da linha de transmissão

## 5.2 Referências

1. FAN, Fei; WU, Gongping; WANG, Man; CAO, Qi; YANG, Song. Multi-robot cyber physical system for sensing environmental variables of transmission line. *\*Sensors\**, v. 18, n. 9, p. 3146, 2018.

2. FONSECA, Alisson; ABDO, Ricardo; ALBERTO, João. Robot for inspection of transmission lines. In: INTERNATIONAL CONFERENCE ON APPLIED ROBOTICS FOR THE POWER INDUSTRY (CARPI), 2., 2012. Anais [...]. [S.l.]: IEEE, 2012. p. 83-87.

3. JIANG, Wei; YAN, Yu; YU, Lianqing; PENG, Menghuai; LI, Hongjun; CHEN, Wei. Research on dual-arm coordination motion control strategy for power cable mobile robot. *\*Transactions of the Institute of Measurement and Control\**, v. 41, n. 11, p. 3235-3247, 2019.

4. LIMA, Eduardo José; BOMFIM, Marcelo Henrique Souza; MOURÃO, Miguel Augusto de Miranda. POLIBOT—power lines inspection robot. *\*Industrial Robot: An International Journal\**, v. 45, n. 1, p. 98-109, 2018.

5. PETERS, James F.; AHN, Tae-Chon; BORKOWSKI, Maciej. Obstacle classification by a line-crawling robot: A rough neurocomputing approach. In: INTERNATIONAL CONFERENCE ON ROUGH SETS AND CURRENT TRENDS IN COMPUTING, 2002. Anais [...]. [S.l.]: Springer, 2002. p. 594-601.



6. POULIOT, Nicolas; RICHARD, Pierre-Luc; MONTAMBAULT, Serge. LineScout power line robot: Characterization of a UTM-30LX LIDAR system for obstacle detection. In: IEEE/RSJ INTERNATIONAL CONFERENCE ON INTELLIGENT ROBOTS AND SYSTEMS, 2012. Anais [...]. [S.l.]: IEEE, 2012. p. 4327-4334.

7. QIN, Xinyan; WU, Gongping; LEI, Jin; FAN, Fei; YE, Xuhui. Detecting inspection objects of power line from cable inspection robot LiDAR data. *\*Sensors\**, v. 18, n. 4, p. 1284, 2018.

8. QIN, Xinyan; WU, Gongping; YE, Xuhui; HUANG, Le; LEI, Jin. A novel method to reconstruct overhead high-voltage power lines using cable inspection robot LiDAR data. *\*Remote sensing\**, v. 9, n. 7, p. 753, 2017.

9. QING, Zhou; XIAO-LONG, Zhou; XIN-PING, Li; JIE, Xiao; TING, Zhou; CHENG-JIANG, Wang. Mechanical design and research of a novel power lines inspection robot. In: INTERNATIONAL CONFERENCE ON INTEGRATED CIRCUITS AND MICROSYSTEMS (ICICM), 2016. Anais [...]. [S.l.]: IEEE, 2016. p. 363-366.

10. QUIGLEY, Morgan; GERKEY, Brian; CONLEY, Ken; FAUST, Josh; FOOTE, Tully; LEIBS, Jeremy; BERGER, Eric; WHEELER, Rob; NG, Andrew. ROS: an open-source Robot Operating System. In: IEEE INTERNATIONAL CONFERENCE ON ROBOTICS AND AUTOMATION (ICRA) WORKSHOP ON OPEN SOURCE ROBOTICS, 2009, Kobe, Japão. Anais [...]. Kobe: IEEE, 2009.

11. RICHARD, Pierre-Luc; POULIOT, Nicolas; MONTAMBAULT, Serge. Introduction of a LIDAR-based obstacle detection system on the LineScout power line robot. In: IEEE/ASME INTERNATIONAL CONFERENCE ON ADVANCED INTELLIGENT MECHATRONICS, 2014. Anais [...]. [S.l.]: IEEE, 2014. p. 1734-1740.

12. ROHMER, E.; SINGH, S. P. N.; FREESE, M. V-REP: A versatile and scalable robot simulation framework. In: IEEE/RSJ INTERNATIONAL CONFERENCE ON INTELLIGENT ROBOTS AND SYSTEMS, 2013. Anais [...]. [S.l.]: IEEE, 2013. p. 1321-1326.

13. SONG, Yifeng; WANG, Lin; JIANG, Yong; WANG, Hongguang; JIANG, Wendong; WANG, Cancan; CHU, Jinliang; HAN, Dongfeng. A vision-based method for the broken spacer detection. In: IEEE INTERNATIONAL CONFERENCE ON CYBER TECHNOLOGY IN AUTOMATION, CONTROL, AND INTELLIGENT SYSTEMS (CYBER), 2015. Anais [...]. [S.l.]: IEEE, 2015. p. 715-719.

14. TONG, Baoen. Research Status and Development Trend of Obstacle Crossing Mechanism of HV Transmission Line Inspection Robot. *Journal of Engineering Research and Reports*, v. 26, n. 5, p. 83-92, 2024.

15. WANG, Yanjun; CHEN, Qi; LIU, Lin; LI, Xiong; SANGAIAH, Arun Kumar; LI, Kai. Systematic comparison of power line classification methods from ALS and MLS point cloud data. *\*Remote Sensing\**, v. 10, n. 8, p. 1222, 2018.

16. YUE, Xiang; WANG, Hongguang; JIANG, Yong. A novel 110 kV power line inspection robot and its climbing ability analysis. *\*International Journal of Advanced Robotic Systems\**, v. 14, n. 3, p. 1729881417710461, 2017.

17. ZHU, Yanhuan; WANG, Xin; XU, Bo. Design of vision-based obstacle crossing of high-voltage line inspection robot. In: *IEEE INTERNATIONAL CONFERENCE ON CYBER TECHNOLOGY IN AUTOMATION, CONTROL, AND INTELLIGENT SYSTEMS (CYBER)*, 2016. Anais [...]. [S.l.]: IEEE, 2016. p. 506-511.